

SW스타랩 졸업생 및 재학생 협력워크숍

.....

2023. 06. 20.

구건모

LG전자 인공지능연구소

목차

1. 발표자 소개
2. 컴퓨터 이론 및 응용 연구실
3. SW스타랩
4. LG전자 인공지능연구소
5. AI코딩 어시스턴트

발표자 소개

학력

- 인천대학교 컴퓨터공학부 공학사, 2014
- 서울대학교 컴퓨터공학부 공학박사, 2021

수상

- 제 1회 TOPCIT 경진대회 대상 (지식경제부 주최), 2012
- 제 2회 TOPCIT 경진대회 은상 (미래창조과학부 주최), 2013
- 제 14회 공개SW 개발자 대회 금상 (과학기술정보통신부 주최), 2020

경력

- LG전자 인공지능연구소 선임연구원, 2022 - 현재

컴퓨터 이론 및 응용 연구실

- String Algorithms
 - » G. M. Landau et al. "Linear-time longest-common-prefix computation in suffix arrays and its applications." CPM 2001.
 - » D. K. Kim, J. S. Sim, H. Park, and K. Park. "Linear-time construction of suffix arrays." CPM 2003.
 - » J. Kim et al. "Order-preserving matching." Theoretical Computer Science 525 (2014): 68–79.
- Graph Algorithms
 - » M. Han et al. "Efficient subgraph matching: Harmonizing dynamic programming, adaptive matching order, and failing set together." SIGMOD 2019.
 - » G. Gu et al. "Scalable graph isomorphism: Combining pairwise color refinement and backtracking via compressed candidate space." ICDE 2021.
- Bioinformatics, Cryptography, Financial Engineering

SW스타랩

NP-hard 그래프 문제를 위한 실용적인 알고리즘 프레임워크 (2018 - 현재)

- 세계 최고 성능의 NP-hard 그래프 알고리즘 개발
- Subgraph isomorphism과 같이 대규모 실제 그래프 데이터에서 빠르게 풀어야 하는 중요 NP-hard 문제
- Subgraph isomorphism 문제를 실제 데이터에서 이전 최고 성능 알고리즘보다 최대 10,000배 빠르게 푸는 알고리즘 개발 (SIGMOD 2019)
- Graph isomorphism 문제를 실제 데이터에서 이전 최고 성능 알고리즘보다 평균 수천 배 빠르게 푸는 알고리즘 개발 (ICDE 2021)
- SIGMOD, VLDB, ICDE 등 데이터베이스 분야 최상위 학회 논문 다수 게재




그림. Subgraph isomorphism의 예. 데이터 그래프 G 에서 쿼리 그래프 q 를 검색하면 $\{(u_1, v_1), (u_2, v_4), (u_3, v_5), (u_4, v_{10})\}$ 이렇게 한 개의 embedding이 나온다(파선으로 표시).

LG전자 인공지능연구소

- LG전자 CTO부문 선행연구 조직
- 주로 가전제품에 들어가는 인공지능을 개발하여 사업부로 이관
- 자연어처리, 컴퓨터비전, 음성인식, 퀀텀 컴퓨팅 등 다양한 분야
- 출퇴근: 유연근무, 주 2회 재택
- 근무위치: 서초, 마곡




AI코딩 어시스턴트

- Copilot (GitHub), Tabnine (Tabnine), CodeWhisperer (AWS) 등 상용화된 기술
- Copilot을 사용하면 코딩 시간 단축 (2시간 41분 → 1시간 11분)
- Google의 AlphaCode는 프로그래밍 대회 상위 54%의 실력
- 코드 유출 우려
- LG전자 SW개발자를 위한 AI모델 자체 개발

```
sentiments.ts  write_sql.go  parse_expenses.py  addresses.rb


1 #!/usr/bin/env ts-node
2
3 import { fetch } from "fetch-h2";
4
5 // Determine whether the sentiment of text is positive
6 // Use a web service
7 async function isPositive(text: string): Promise<boolean> {
8   const response = await fetch('http://text-processing.com/api/sentiment/', {
9     method: "POST",
10    body: `text=${text}`,
11    headers: {
12      "Content-Type": "application/x-www-form-urlencoded",
13    },
14  });
15  const json = await response.json();
16  return json.label === "pos";
17 }
```

Copilot



AI코딩 어시스턴트

- 언어 모델은 모델 크기와 학습 데이터 양이 커질수록 성능이 좋아짐
- Challenges
 - » 수백 ~ 수천 개의 GPU를 이용한 분산 학습
 - » 수백 GB ~ 수 TB의 데이터에 대한 전처리



Model size (params)	Training tokens (round)	Training data used (estimate)	How much data is that? If 1 book is about 500KB of text (estimate)
Chinchilla/			
More books than in...²³			
70B	1.4 Trillion	2.3TB	The Kindle store on Amazon US (6.4M).
250B	5 Trillion	8.3TB	All 30 libraries at Yale University (16.6M).
500B	10 Trillion	16.6TB	The Google Books collection (33.2M).
1T	20 Trillion	33.3TB	The US Library of Congress (66.6M).
10T	200 Trillion	333TB	All US public libraries combined (666M).
100T	2 Quadrillion	3.3PB	All bibles ever sold worldwide (6.6B).
250T	5 Quadrillion	8.3PB	A stack all the way to the Moon (16.6B).
500T	10 Quadrillion	16.6PB	4 books about every living human (33.2B).

Table: Dataset sizes needed to align with Chinchilla data optimization for models.

감사합니다!